

ІНФОРМАТИКА · 10 КЛАС · УРОК 11

Статистичний аналіз даних

Пошук наборів даних

Тема 2 · § 2.2, стор. 42–48 · чотири характеристики й одне правило

I семестр

Половину теми ви вже проходили


- Книжка сама пише: «Вам уже відомо з курсу АЛГЕБРИ 9-го класу...»
- Звідти: вибірка, середнє арифметичне, медіана, мода
- З 9 класу інформатики: ряди даних у таблиці, функції, діаграми
- Нове тут тільки одне — СТАНДАРТНЕ ВІДХИЛЕННЯ
- І головне: як усе це рахувати таблицею й ЯК ЧИТАТИ результат

Статистика й вибірка

- Статистика — методи аналізу даних, що характеризують МАСОВІ ЯВИЩА
- Щоб побачити тенденцію, потрібні сотні тисяч даних
- Обстежити стількох людей неможливо. Тому беруть ВИБІРКУ —
- частину об'єктів, на якій і проводять дослідження
- Ряди даних — дані з кожного рядка й стовпця таблиці вибірки

Дві вимоги — і друга важливіша

- **МАСОВІСТЬ:** що більше вибірка, то точніше аналіз
- **РЕПРЕЗЕНТАТИВНІСТЬ:** у вибірці мають бути РІЗНІ об'єкти —
 - різних регіонів, різної статі, різного віку
- Розмір робить аналіз **ТОЧНИШИМ**.
Репрезентативність — **ПРАВИЛЬНИМ**
- Можна опитати мільйон людей з одного міста — і помилитися



Вибірка — це не «менше даних»


- Синоптики збирають дані про погоду ПОНАД 160 РОКІВ
- Треба спрогнозувати погоду у Львові на першу декаду червня
- Беруть НЕ всі 160 років, а дані за 10–15 років,
- саме про ЛЬВІВ і саме про ПЕРШУ ДЕКАДУ ЧЕРВНЯ
- Отже вибірка — це не «менше даних». Це ПОТРІБНІ дані

Що рахуємо і якими функціями

- СЕРЕДНЄ АРИФМЕТИЧНЕ — AVERAGE
- якими були б значення, ЯКБИ ВОНИ ВСІ БУЛИ ОДНАКОВІ
- СТАНДАРТНЕ ВІДХИЛЕННЯ — STDEV.P
- МОДА — MODE.SNGL · МЕДІАНА — MEDIAN
- Мод може бути КІЛЬКА. А іноді моди немає взагалі


Чи можна вірити середньому

- Показує, наскільки ШИРОКО розкидані значення відносно середнього
- Ряд $2,5 \cdot 2,8 \cdot 2,3 \cdot 2,55 \cdot 2,47 \rightarrow$ середнє $2,524$, відхилення $\approx 0,16$
- Ряд $4,7 \cdot 6,2 \cdot 5,1 \cdot 12,4 \cdot 14,1 \rightarrow$ середнє $8,5$, відхилення $\approx 3,95$
- П'ять чисел в обох. Але $8,5$ не схоже НІ на $4,7$, НІ на $14,1$
- Маленьке відхилення $\rightarrow$ середньому вірити можна. Велике $\rightarrow$ не варто



Найчастіше — і посередині

- МОДА — значення, що повторюється найчастіше
- Де показова: ціни на ринку, які РОЗМІРИ взуття купують найбільше
- МЕДІАНА — ділить упорядкований ряд на дві РІВНІ частини
- Непарна кількість → середній член. Парна → середнє двох середніх
- Медіаною визначають, ДЕ ПОБУДУВАТИ школу чи магазин




Коли медіана показовіша за середнє

- Дані відрізняються МАЛО → показові і середнє, і медіана
- Дані відрізняються СИЛЬНО → МЕДІАНА ПОКАЗОВІША
- Причина: один викид тягне середнє за собою, а медіану — ні
- Тому питання не «яка характеристика правильна». Усі чотири правильні
- Питання: ЯКА З НИХ ПОКАЗОВА ДЛЯ ЦЬОГО РЯДУ



Масштаб не робить висновок правильним

- Велика НЕрепрезентативна вибірка гірша за малу репрезентативну
- Не бо менш точна — а бо ПЕРЕКОНЛИВІША. «Ми опитали 50 тисяч»
- Опитування «чи зручно вчитися онлайн» — в Інтернеті. У чому проблема?
- Воно опитає лише тих, у кого Інтернет Є. Це цифровий розрив, урок 6
- Відкриті дані (урок 6) — щоб можна було ВЗЯТИ Й ПЕРЕВІРИТИ САМОМУ



Не «скільки», а «кого саме опитали»

- За кожним рядком у наборі даних стоїть ЛЮДИНА
- Три питання, у яких немає простих відповідей:
- чиї дані в наборі — і чи вони погоджувались (урок 4)
- які висновки роблять про людей на основі цих даних
- хто перевірить, що вибірка репрезентативна — для цього й ВІДКРИТІ ДАНІ

Що зробити до наступного уроку

- 0. ОПИТУВАННЯ — заповнюємо ЗАРАЗ, посилання в чаті. Дві хвилини, анонімно
- На ваших даних будуватиметься ПР № 3 наступного уроку
- 1. § 2.2, стор. 42–48. Буде квіз
- 2. Опади: знайти 12 чисел + ДЖЕРЕЛО + 4 характеристики + 2 висновки
- Якщо MODE.SNGL дасть помилку — це ПРАВИЛЬНИЙ результат. Так і напишіть